Lekcja 01 – Data Science i Machine Learning

Odpowiedzi do zadań 8–20

Zadanie 8 – Przykłady zastosowań DS dla ekologii

Projekt 1: Prognoza produkcji energii z farmy wiatrowej

- **Problem:** operator sieci nie wie z wyprzedzeniem, ile prądu dadzą turbiny, więc na wszelki wypadek trzyma w rezerwie bloki węglowe.
- **Typ zadania ML:** regresja (prognoza szeregu czasowego).
- **Dane:** prognozy pogody (prędkość i kierunek wiatru, ciśnienie, temperatura), historyczna produkcja każdej turbiny, dane techniczne turbin, godzina i pora roku.
- **Wpływ na środowisko:** mniejsza rezerwa z elektrowni węglowych i mniej marnowanej energii odnawialnej.

Projekt 2: Wykrywanie wylesiania ze zdjęć satelitarnych

- **Problem:** nielegalne wycinki są wykrywane za późno, często po miesiącach.
- **Typ zadania ML:** segmentacja / klasyfikacja obrazów (detekcja zmian między datami).
- **Dane:** zdjęcia satelitarne (Sentinel-2, Landsat) z kolejnych tygodni, mapy obszarów chronionych, historyczne zgłoszenia wycinek.
- **Wpływ na środowisko:** reakcja służb w dni zamiast w miesiące, ochrona lasów pochłaniających CO2.

Projekt 3: Optymalizacja wywozu odpadów

- **Problem:** śmieciarki jeżdżą stałą trasą i opróżniają w połowie puste kontenery, spalając paliwo.
- **Typ zadania ML:** regresja (prognoza zapełnienia kontenera) + optymalizacja trasy.
- **Dane:** czujniki poziomu zapełnienia, historia wywozów, kalendarz (święta, weekendy), GPS pojazdów, mapa drogowa.
- **Wpływ na środowisko:** mniej przejechanych kilometrów, mniej spalin i hałasu w mieście.

Zadanie 9 – Projektowanie systemu rekomendacji

Typ zadania ML

Ranking – układamy listę filmów od najbardziej do najmniej trafnego. Pod spodem działa model predykcyjny: regresja (jaka będzie ocena) lub klasyfikacja (czy użytkownik obejrzy do końca).

Potrzebne dane

- **Użytkownik:** historia oglądania, oceny, język, kraj, urządzenie.
- **Film:** gatunek, rok, obsada, długość, opis, popularność.
- **Interakcje:** co obejrzał, ile minut, co porzucił po 5 minutach, w co kliknął i nie obejrzał.
- **Kontekst:** pora dnia, dzień tygodnia, urządzenie.

Najcenniejsze są interakcje – mówią więcej niż deklarowane preferencje.

Podejście do uczenia

Supervised, hybrydowe:

- *Collaborative filtering* – "użytkownicy podobni do Ciebie obejrzeli X". Daje najlepszą trafność, ale nie działa dla nowych filmów i nowych użytkowników (problem zimnego startu).
- *Content-based* – podobieństwo cech filmu. Ratuje zimny start.

Łączymy oba: content-based dla nowości, collaborative dla reszty.

Metryka oceny

- **Offline:** NDCG@10 i Recall@10 – czy trafione pozycje są wysoko na liście.
- **Online (ważniejsze):** test A/B – czas oglądania, odsetek kliknięć, utrzymanie subskrypcji.

Optymalizacja Green AI

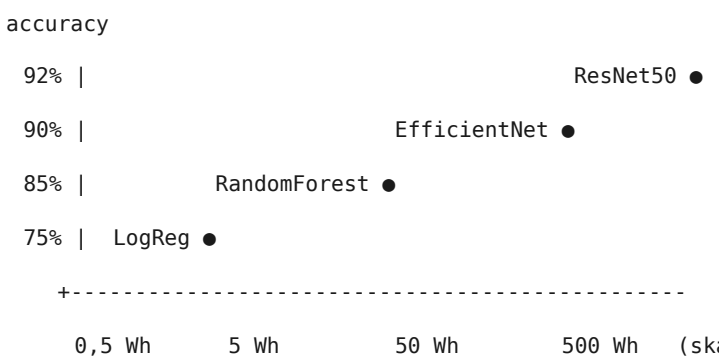
- 1. **Dwuetapowy ranking:** tani model wybiera 500 kandydatów z katalogu, drogi model ocenia tylko te 500.
- 2. **Przeliczanie w batchu:** profile i embeddingi liczone raz na dobę, nie przy każdym wejściu.
- 3. **Cache:** gotowa lista rekomendacji ważna kilka godzin.
- 4. **Retrening tylko przy spadku jakości**, nie codziennie z przyzwyczajenia.
- 5. **Trening w regionie chmury z zieloną energią.**

Zadanie 10 – Analiza trade-off: dokładność vs energia

Efficiency ratio (accuracy / Wh)

Model	Accuracy	Energia	Efficiency ratio
Logistic Regression	75%	0,5 Wh	**150,0**
Random Forest	85%	5 Wh	**17,0**
EfficientNet	90%	50 Wh	**1,8**
ResNet50	92%	500 Wh	**0,18**

Wykres konceptualny



Krzywa się wypłaszcza: **ostatnie 2 punkty procentowe kosztują 10x więcej energii niż całe poprzednie 15 punktów.** To klasyczne prawo malejących przychodów.

Kiedy który model

- **Logistic Regression** – baseline na start projektu, ogromna skala, bardzo tanie urządzenia.
- **Random Forest** – dane tabelaryczne, średnia skala, gdy potrzebna wyjaśnialność.
- **EfficientNet** – domyślny wybór produkcyjny, najlepszy kompromis.
- **ResNet50** – gdy błąd kosztuje więcej niż energia.

Aplikacja mobilna → EfficientNet

Został zaprojektowany pod urządzenia o ograniczonych zasobach. Daje 90% przy 10x mniejszym zużyciu niż ResNet50. Na telefonie liczy się bateria i czas odpowiedzi, a 2 punkty procentowe nie są warte rozładowanego telefonu.

System bezpieczeństwa w elektrowni jądrowej → ResNet50

Koszt błędu jest nieporównywalny z kosztem energii. 500 Wh to ułamek grosza, a przeoczona usterka to katastrofa. Zasilanie jest stałe, urządzenie nie działa na baterii. Dodatkowo: kilka modeli głosujących i obowiązkowe potwierdzenie przez człowieka.

Zadanie 11 – Design case: wykrywanie fraudu

Typ zadania ML

Klasyfikacja binarna (fraud / nie fraud), w praktyce scoring: model zwraca prawdopodobieństwo, a próg ustawiamy biznesowo.

Supervised czy unsupervised? – Oba

- **Supervised** jako podstawa: mamy etykiety z reklamacji i chargebacków. Model uczy się znanych schematów oszustw.
- **Unsupervised** (detekcja anomalii) jako uzupełnienie: wyłapuje **nowe** schematy, których nie ma w danych historycznych. Oszuści ciągle zmieniają metody, więc sam supervised zawsze będzie spóźniony.

Wyzwania

Wyzwanie	Rozwiązanie
Imbalanced data (0,1%)	Ważenie klas, undersampling większości, metryki inne niż accuracy
Opóźnione etykiety (chargeback po tygodniach)	Trenowanie na danych sprzed kilku tygodni, osobny model na świeże anomalie
Concept drift	Monitoring jakości, retrening przy spadku
Limit czasu < 100 ms	Lekki model, cechy liczone wcześniej
Koszt FP vs FN	Próg dobrany pod koszt w złotówkach, nie pod F1

Ocena modelu

Nie accuracy – model mówiący zawsze "nie fraud" ma 99,9% accuracy i jest bezużyteczny.

Używamy: **precision, recall, PR-AUC**. Kluczowa jest też metryka operacyjna: **recall przy limicie alertów**, który zespół jest w stanie obsłużyć dziennie. Próg wybieramy tam, gdzie koszt zablokowanych uczciwych klientów równoważy się ze stratami z oszustw.

Energooszczędność przy 10 mln transakcji dziennie

- 1. **Kaskada:** proste reguły odsiewają ~99% oczywiście poprawnych transakcji; model widzi tylko 1%. To redukuje koszt stukrotnie.
- 2. **Lekki model** (gradient boosting) zamiast sieci głębokiej – przy danych tabelarycznych daje porównywalną jakość za ułamek energii.
- 3. **Feature store:** cechy klienta liczone raz i współdzielone, nie przeliczane przy każdej transakcji.
- 4. **Inference na CPU**, bez GPU.
- 5. **Retrening tygodniowy lub wyzwalany driftem**, nie codzienny.

Zadanie 12 – Comparison: reguły vs ML w moderacji komentarzy

Rozwiązanie oparte na regułach

Lista słów zabronionych, wyrażenia regularne (także na próby obejścia typu "k*rwa"), limity: dużo wielkich liter, linki, powtórzenia, czarna lista użytkowników.

Rozwiązanie oparte na ML

Klasyfikator tekstu uczony na oznaczonych komentarzach. Wersja tania: TF-IDF + regresja logistyczna. Wersja dokładna: dostrojony model transformerowy.

Tabela porównawcza

Kryterium	Reguły	Machine Learning
Dokładność	60–70%	85–93%
Rozumienie kontekstu	brak (blokuje "nie bądź dupkiem" i cytaty)	dobre
Ironia, obraza bez wulgaryzmów	nie wykrywa	wykrywa częściowo
Łatwość utrzymania	trudna – lista rośnie w nieskończoność	łatwiejsza – dodajemy przykłady, nie reguły
Zużycie energii	praktycznie zerowe	trening + koszt każdej predykcji
Koszt wdrożenia	niski	wyższy (dane, etykietowanie, infrastruktura)
Wyjaśnialność	pełna ("słowo X z listy")	ograniczona

Kryterium	Reguły	Machine Learning
Szybkość reakcji na nowe zjawisko	natychmiastowa	wymaga danych i retreningu

Co jest lepsze?

ML wygrywa na dokładności, ale sam w sobie nie jest najlepszym wyborem. Reguły są bezkonkurencyjne na oczywistych przypadkach i nic nie kosztują.

Rozwiązanie hybrydowe (rekomendowane)

- 1. **Warstwa 1 – reguły:** oczywiste wulgaryzmy i spam blokowane natychmiast, bez uruchamiania modelu. Odsiewa znaczną część ruchu za darmo.
- 2. **Warstwa 2 – lekki model ML:** ocenia resztę i zwraca prawdopodobieństwo toksyczności.
- 3. **Warstwa 3 – człowiek:** przypadki niepewne (wynik 0,4–0,6) trafiają do moderatora. Jego decyzje wracają jako nowe dane treningowe.

Taki układ daje dokładność ML przy znacznie niższym koszcie energii i zachowuje kontrolę człowieka tam, gdzie jest potrzebna.

Zadanie 13 – Design end-to-end: Smart City Traffic

Potrzebne dane

- Czujniki ruchu: pętle indukcyjne, kamery (liczba pojazdów, długość kolejek).
- Dane GPS z nawigacji i z floty komunikacji miejskiej (prędkości, czasy przejazdu).
- Aktualny stan i program sygnalizacji.
- Pogoda, kalendarz (święta, mecze, remonty), zdarzenia drogowe.
- Mapa sieci drogowej z geometrią skrzyżowań.
- Pomiary jakości powietrza (do oceny efektu).

Typy zadań ML (jest ich kilka)

- 1. **Detekcja obiektów** – zliczanie pojazdów, pieszych i rowerzystów z kamer.
- 2. **Regresja / szeregi czasowe** – prognoza natężenia ruchu na najbliższe 15–60 minut.
- 3. **Klasyfikacja** – wykrywanie zdarzeń: wypadek, blokada, pojazd uprzywilejowany.
- 4. **Reinforcement learning** – sterowanie fazami świateł (zadanie główne).
- 5. **Klasteryzacja** – grupowanie typowych wzorców dni i skrzyżowań, osobne strategie dla każdego typu.

Podejścia do uczenia

- Supervised dla detekcji i prognoz.
- RL dla sterowania – uczone **najpierw w symulatorze** (np. SUMO), bo eksperymentowanie na żywym mieście jest niedopuszczalne. Wdrożenie z twardymi ograniczeniami bezpieczeństwa (minimalny czas zielonego, maksymalny czas czerwonego).

Pomiar sukcesu

- **Techniczne:** średni czas przejazdu korytarzem, liczba zatrzymań, długość kolejek.
- **Biznesowe / miejskie:** emisja CO2 i NOx, zużycie paliwa, czas przejazdu karetek i straży, liczba wypadków, czas oczekiwania pieszych.
- **Metodyka:** test A/B – skrzyżowania z systemem vs porównywalne skrzyżowania bez niego, w tym samym okresie.

Green AI

- Trening agenta RL w symulatorze – tanio, bez zużycia paliwa przez prawdziwe auta.
- **Przetwarzanie obrazu lokalnie na sterowniku** (edge). Do centrum wysyłamy liczby, nie strumień wideo. To największa oszczędność: transmisja i przetwarzanie wideo w chmurze są wielokrotnie droższe.
- Małe, skwantyzowane modele wizyjne na urządzeniach.
- Retrening sezonowy, nie ciągły.
- **Bilans netto:** system zużywa energię, ale oszczędza paliwo tysięcy samochodów dziennie. Ten bilans trzeba policzyć i raportować – to uzasadnienie projektu.

Ryzyka i wyzwania etyczne

- **Prywatność:** kamery rejestrują ludzi i tablice. Rozwiązanie: anonimizacja na urządzeniu, zapisywanie tylko zliczeń, brak przechowywania nagrań.
- **Sprawiedliwość:** optymalizacja "przepustowości" potrafi faworyzować arterie przelotowe kosztem osiedli i pieszych. Trzeba wprost nagradzać krótki czas oczekiwania pieszych i rowerzystów.
- **Bezpieczeństwo:** przy awarii lub dziwnym zachowaniu agenta automatyczne przejście na stały, sprawdzony program.
- **Cyberbezpieczeństwo:** sygnalizacja to infrastruktura krytyczna.
- **Odpowiedzialność:** kto odpowiada za wypadek przy sterowaniu automatycznym – miasto musi to ustalić przed wdrożeniem.

Zadanie 14 – Semi-Supervised Strategy

Jak wykorzystać 1 000 opisanych zdjęć

- Podzielić: ~700 trening, ~150 walidacja, ~150 test odłożony na sam koniec. **Zbiór testowy musi zostać nietknięty** – bez niego nie da się uczciwie ocenić efektu.
- Dostroić gotowy model (transfer learning z ResNet lub CLIP) zamiast trenować od zera.

Jak wykorzystać 99 000 nieopisanych zdjęć

- 1. **Self-supervised pretraining** (np. SimCLR, DINO): model uczy się rozpoznawać, że dwa wycinki tego samego zdjęcia to to samo. Nie potrzebuje etykiet, a uczy się dobrych reprezentacji butów, koszul i spodni.
- 2. **Pseudo-labeling:** model bazowy etykietuje nieopisane zdjęcia; bierzemy tylko te z pewnością powyżej 0,95, dokładamy do treningu, powtarzamy 2–3 razy.
- 3. **Active learning:** wybieramy 500 zdjęć, co do których model jest najbardziej niepewny, i dajemy je człowiekowi do opisania. To najwyższy zysk jakości na jedną etykietę.

Konkretna metodologia (krok po kroku)

- 1. DINO na wszystkich 100 000 zdjęć (bez etykiet) → dobry backbone.
- 2. Fine-tuning na 700 opisanych zdjęciach.
- 3. Pseudo-labeling z progiem pewności, 2–3 iteracje.
- 4. Active learning: 500 najtrudniejszych zdjęć do opisania przez człowieka.
- 5. Finalny fine-tuning.

Porównanie z baseline

Ten sam odłożony zbiór testowy, ta sama metryka. Baseline = fine-tuning tylko na 700 etykietach. Patrzymy na **F1 makro** (nie accuracy), bo klasy rzadkie są tu najtrudniejsze – i to one pokazują, czy semi-supervised faktycznie pomógł.

Oszczędność energii – uczciwie

- Względem **opisania wszystkich 100 000 zdjęć**: oszczędzamy przede wszystkim pracę ludzką – 99 000 zdjęć × ~10 s to około 275 roboczogodzin i odpowiadający im koszt.
- Ale uwaga: **self-supervised pretraining sam w sobie zużywa więcej energii niż zwykły fine-tuning** (dziesiątki godzin GPU). Jest tańszy niż trening dużej sieci od zera, ale nie jest "darmowy".
- Wniosek: główny zysk to koszt i czas etykietowania, nie kilowatogodziny. ROI liczymy na koszcie całkowitym (ludzie + sprzęt + energia), a nie na samym zużyciu prądu.

Zadanie 15 – Reinforcement Learning Design

Formalny opis problemu

Agent: system sterowania budynkiem. Kontroluje ogrzewanie (temperatura zadana), klimatyzację, wentylację, oświetlenie i rolety.

Environment: budynek wraz z pogodą i mieszkańcami.

Stan (state):

- temperatura wewnątrz (per strefa) i na zewnątrz,
- wilgotność, poziom CO2,
- obecność i liczba osób,
- pora dnia, dzień tygodnia, pora roku,
- prognoza pogody i nasłonecznienie,
- aktualna cena energii,
- stan urządzeń.

Akcje (actions):

- zmiana temperatury zadanej o ±0,5 °C,
- włączenie / wyłączenie / zmiana biegu wentylacji,
- ściemnienie lub wyłączenie oświetlenia,
- otwarcie lub zamknięcie rolet (darmowe ciepło i chłodzenie).

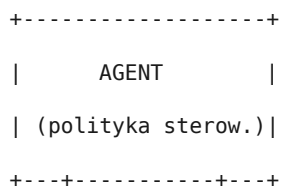
Funkcja nagrody:

```
r = - (a * zużyta_energia_kWh * cena)
   - (b * dyskomfort)
   - (c * liczba_przełączeń)


gdzie dyskomfort = odchylenie od strefy komfortu (20–24 °C),
liczone TYLKO gdy w pomieszczeniu są ludzie;
dodatkowa kara, gdy CO2 > 1000 ppm.
```

Kara za częste przełączanie chroni urządzenia przed zużyciem. Wagi a, b, c ustala właściciel budynku – to one definiują, ile komfortu jest wart kilowatogodzinę.

Diagram agent-environment loop





Czy da się to rozwiązać supervised learning? Dlaczego RL jest lepsze

Supervised wymaga "poprawnych odpowiedzi". Tutaj ich nie ma – **nikt nie wie, jaka akcja jest optymalna**, znamy tylko skutki podjętych decyzji.

Supervised mógłby co najwyżej nauczyć się naśladować obecnego operatora, czyli **odtworzyć jego nieefektywność**. RL potrafi znaleźć strategię lepszą niż wszystko, co jest w danych historycznych.

Drugi, ważniejszy powód: **decyzje są sekwencyjne i mają skutki odroczone.** Podgrzanie budynku teraz wpływa na temperaturę za dwie godziny. Liczy się suma nagród w czasie, a nie trafność pojedynczej decyzji. Supervised uczy się punktowo, RL optymalizuje całą trajektorię.

Uwaga praktyczna: agenta uczymy najpierw w symulatorze (np. EnergyPlus). Eksploracja losowych akcji w prawdziwym budynku oznaczałaby zmarzniętych ludzi. Wdrażamy z twardymi limitami bezpieczeństwa, których agent nie może przekroczyć.

Zadanie 16 – Multi-Model System Design

Komponenty

#	Zadanie	Typ ML	Podejście	Energochłonność
1	Klasyfikacja zdjęć produktów	Klasyfikacja obrazów	Supervised, transfer learning	Średnia
2	Generowanie opisów	Generowanie tekstu	Gotowy LLM + prompt / LoRA	**Wysoka**
3	Rekomendacje	Ranking	Supervised + collaborative filtering	Średnia, ale ogromna skala

#	Zadanie	Typ ML	Podejście	Energochłonność
4	Fałszywe recenzje	Klasyfikacja binarna + anomalie	Supervised + unsupervised	Niska

Architektura

```
  zdjęcie produktu
        |
        v
[1] KLASYFIKATOR OBRAZÓW ---> kategoria + atrybuty
        |                              |
        v                              v
embedding produktu  ----------> [2] GENERATOR OPISÓW
        |                              |
        |                              v
        |                        opis w bazie
        v                        (liczony RAZ)
+---------------------+
|    FEATURE STORE    | <--- historia zakupów, kliknięcia
+----------+----------+
         |
         v
[3] REKOMENDACJE  <--- filtr jakości <--- [4] DETEKTOR FAŁSZYWYCH RECENZJI
         |
         v
   lista dla użytkownika
```

Jak komponenty współpracują

- Wspólny **feature store** i wspólne embeddingi produktów – liczone raz, używane przez wszystkie modele.
- Klasyfikator zdjęć nadaje kategorię, która jest wejściem dla generatora opisów i dla rekomendacji content-based (rozwiązuje zimny start nowych produktów).
- Detektor fałszywych recenzji obniża ocenę produktu, co wpływa na ranking – rekomendacje nie promują produktów z kupionymi opiniami.

Najbardziej energochłonne

- 1. **Generator opisów (LLM)** – najdroższy na pojedyncze wywołanie.
- 2. **Rekomendacje** – pojedyncze zapytanie jest tanie, ale przy milionach zapytań

dziennie sumarycznie mogą kosztować więcej niż LLM.

Plan optymalizacji Green AI

- 1. **Nie trenować LLM od zera** – użyć gotowego modelu z dobrym promptem lub lekkim dostrojeniem (LoRA). To różnica rzędu tysięcy razy.
- 2. **Opisy generować raz i zapisywać w bazie.** Opis produktu nie zmienia się co sekundę – to nie musi być operacja czasu rzeczywistego. Największa pojedyncza oszczędność w całym systemie.
- 3. **Wspólny backbone wizyjny** dla klasyfikacji i wyszukiwania po obrazie zamiast dwóch osobnych sieci.
- 4. **Destylacja** dużego modelu do małego na potrzeby predykcji produkcyjnej.
- 5. **Dwuetapowe rekomendacje** (tani filtr → drogi ranking) + cache.
- 6. **Autoskalowanie GPU**, żeby karty nie stały włączone bez pracy – to częste i kosztowne marnotrawstwo.
- 7. **Monitoring kWh per komponent** – bez pomiaru nie ma optymalizacji.

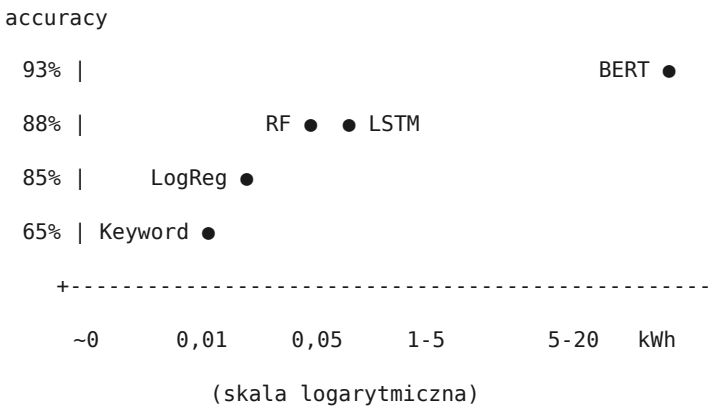
Zadanie 17 – Benchmark: Energy vs Accuracy (klasyfikacja tekstu)

Poniższe liczby to **szacunki rzędu wielkości** na typowym zbiorze kilkudziesięciu tysięcy dokumentów, nie wyniki pomiaru.

Podejście	Accuracy	Energia treningu	Energia predykcji	Czas treningu	Czas predykcji	Łatwość wdrożenia
Keyword matching	60–70%	~0 (brak treningu)	~0	godziny pracy człowieka	< 1 ms	bardzo łatwe
Logistic Regression (TF-IDF)	82–88%	~0,01 kWh	~0,001 Wh	minuty (CPU)	< 1 ms	łatwe
Random Forest	83–88%	~0,05 kWh	~0,01 Wh	minuty–godziny (CPU)	1–5 ms	łatwe
LSTM	86–90%	~1–5 kWh	~0,1 Wh	godziny (GPU)	~10 ms	średnie
BERT (fine-tuning)	91–94%	~5–20 kWh	~0,5–1 Wh	godziny (GPU)	20–50 ms (GPU)	trudniejsze

Ważne zastrzeżenie: energia treningu BERT dotyczy tylko dostrojenia. Wstępne wytrenowanie modelu bazowego to rząd setek–tysięcy kWh, ale ponosi je raz autor modelu, a korzystają z niego wszyscy. To jest sedno idei transfer learningu jako praktyki Green AI.

Wykres accuracy vs energia



Skok z 65% na 86% kosztuje grosze. Skok z 86% na 93% kosztuje **sto do tysiąca razy więcej**.

Rekomendacje

Scenariusz	Wybór
Moderacja treści, miliony tekstów dziennie	Reguły + Logistic Regression
Analiza sentymentu w raportach, mały wolumen	BERT – jakość ma tu realną wartość
Urządzenie offline / telefon	Logistic Regression lub destylowany DistilBERT
Dane tabelaryczne z tekstem jako jedną z cech	Random Forest / gradient boosting
Pierwszy prototyp dowolnego projektu	**Zawsze Logistic Regression jako baseline**

Analiza Green AI efficiency

W przeliczeniu na accuracy na kilowatogodzinę **regresja logistyczna jest bezkonkurencyjna** – jest tańsza o kilka rzędów wielkości niż BERT, przy stracie 5–8 punktów procentowych.

Praktyczna zasada: **zacznij od najprostszego modelu, przechodź do droższego tylko wtedy, gdy różnica w jakości przekłada się na mierzalną wartość biznesową.** Bardzo często okazuje się, że nie przekłada się wcale – a baseline i tak jest potrzebny, żeby to w ogóle stwierdzić.

Zadanie 18 – Ethical AI + Green AI (diagnostyka RTG)

Aspekty etyczne: co jeśli model się myli?

Błędy nie są równe. **Fałszywie negatywny** (przeoczona choroba) jest znacznie groźniejszy niż fałszywie pozytywny (dodatkowe badanie). Próg decyzyjny ustawiamy więc tak, by maksymalizować czułość.

Odpowiedzialność: system musi być narzędziem wspierającym radiologa, a nie podejmującym decyzję. Odpowiedzialność za diagnozę zostaje przy lekarzu i placówce; producent odpowiada za jakość, walidację kliniczną i rzetelną dokumentację ograniczeń modelu. W UE taki system to wyrób medyczny i – zgodnie z AI Act – system wysokiego ryzyka: wymaga nadzoru człowieka, logowania decyzji i możliwości odwołania.

Trade-off: czy 99% jest warte 100x energii wobec 97%?

W tym przypadku tak – ale to zła alternatywa.

Dwa punkty procentowe w diagnostyce to realni ludzie: przy 100 000 badań rocznie to 2 000 osób z inną diagnozą. Jednocześnie energia jednego badania AI jest znikoma wobec energii samego aparatu RTG i dojazdu pacjenta do szpitala.

Zamiast godzić się na stukrotny koszt, należy go najpierw zbić metodami, które nie kosztują jakości:

- **kaskada** – tani model odsiewa jednoznacznie prawidłowe zdjęcia, drogi ocenia resztę,
- **kwantyzacja i destylacja** modelu do predykcji,
- jedno porządne, dobrze zaplanowane trenowanie zamiast setek przypadkowych eksperymentów (to zwykle tu ucieka najwięcej energii).

Fairness

Model trzeba oceniać **osobno dla każdej podgrupy**: płeć, wiek, pochodzenie, typ aparatu, szpital. Uśredniona dokładność potrafi ukryć, że dla jednej grupy model działa źle.

Klasyczna pułapka: model uczy się rozpoznawać **szpital** (po oznaczeniu na kliszy lub charakterystyce aparatu), a nie chorobę – bo w jednym szpitalu było więcej przypadków chorych. Zabezpieczenia: zróżnicowany zbiór treningowy, usuwanie oznaczeń ze zdjęć, obowiązkowa **walidacja zewnętrzna na danych z innej placówki**.

Privacy

- Anonimizacja DICOM: usunięcie metadanych pacjenta oraz napisów wypalonych w obrazie.
- Świadoma zgoda na wykorzystanie danych do trenowania.
- Przetwarzanie lokalne (on-premise) zamiast wysyłania zdjęć do chmury.

- **Federated learning** – model jedzie do danych, dane nie opuszczają szpitala.
- Kontrola dostępu, logi, zgodność z RODO.

Green AI

Transfer learning zamiast treningu od zera, ograniczenie liczby eksperymentów przez przemyślany plan, predykcja na CPU lub zoptymalizowanym akceleratorze, dostawca chmury z zieloną energią, pomiar i raportowanie zużycia.

Framework decyzyjny: kiedy trade-off accuracy/energia jest akceptowalny

Cztery pytania w kolejności:

- 1. **Jaka jest cena błędu dla człowieka?** Zdrowie i życie → jakość wygrywa. Rekomendacja filmu → energia wygrywa.
- 2. **Czy różnica w jakości jest statystycznie istotna na niezależnym zbiorze testowym?** Jeśli 99% vs 97% mieści się w przedziale niepewności – wybierz tańszy model. Bardzo często tak właśnie jest.
- 3. **Czy tę jakość da się osiągnąć taniej inaczej?** Kaskada, destylacja, lepsze dane, lepsze etykiety. Zwykle da się.
- 4. **Jaki jest pełny bilans środowiskowy wobec alternatywy?** Dokładniejszy model może oszczędzić niepotrzebne powtórne badania i dojazdy – wtedy zużywa więcej prądu, a mniej zasobów ogółem.

Reguła nadrzędna: im wyższa stawka ludzka, tym mniej waży energia – ale zawsze najpierw wyczerp optymalizacje, które nic nie kosztują w jakości.

Zadanie 19 – Data Science for Climate Change

Wybrany problem

Krótkoterminowa prognoza ryzyka pożaru lasu – przewidywanie na 1–7 dni do przodu, w siatce 1 × 1 km. Służby dostają mapę ryzyka i mogą rozmieścić patrole oraz sprzęt tam, gdzie zagrożenie jest największe.

Typ zadania ML i podejście

- **Klasyfikacja** (czy w danym kwadracie i dniu wybuchnie pożar) lub równoważnie **regresja** indeksu ryzyka.
- **Supervised.** Dane są tabelaryczne i przestrzenne, więc podstawą jest gradient boosting (XGBoost / LightGBM), opcjonalnie wzbogacony o cechy z obrazów satelitarnych.
- Wyzwanie: silnie niezbalansowane dane (pożary są rzadkie) – te same techniki co przy detekcji fraudu.

Dane i źródła

Dane	Źródło
Historia pożarów	NASA FIRMS, dane PSP / Lasów Państwowych
Pogoda i prognozy	ERA5 (Copernicus), IMGW
Wskaźniki roślinności (NDVI), wilgotność	Sentinel-2, Sentinel-3
Typ lasu, wiek drzewostanu	Bank Danych o Lasach
Ukształtowanie terenu	numeryczny model terenu
Bliskość dróg i zabudowy	OpenStreetMap

Prawie wszystkie źródła są otwarte i darmowe – to mocno poprawia ROI projektu.

Pomiar impactu

- Odsetek pożarów, które wystąpiły w kwadratach oznaczonych jako wysokie ryzyko.
- Średni czas od zapłonu do podjęcia akcji gaśniczej.
- Spalona powierzchnia w hektarach, porównana rok do roku **i do regionu kontrolnego bez systemu**.
- Przeliczenie na CO2: 1 ha spalonego lasu to kilkadziesiąt ton uwolnionego CO2 plus utrata zdolności pochłaniania na lata. Oszczędzone tony = uniknięte hektary × współczynnik.

Uczciwe zastrzeżenie: atrybucja jest trudna – susza albo deszczowe lato wpłyną na wynik bardziej niż model. Dlatego konieczne jest porównanie z regionem kontrolnym, a nie samo "rok do roku".

Green AI samego projektu

- Dane tabelaryczne + gradient boosting = godziny CPU, bez GPU.
- Predykcja raz dziennie dla całej siatki w jednym przebiegu wsadowym, nie na żądanie.
- Retrening raz na sezon.
- Buforowanie pobranych danych satelitarnych (pobieranie i dekodowanie to tu realny koszt).

Emisja projektu: rzędu pojedynczych ton CO2 rocznie, głównie z pracy zespołu.

ROI

- **Koszt roczny:** dane darmowe, obliczenia kilkaset złotych miesięcznie, zespół 2 osób – główna pozycja.

- **Korzyść:** w regionie, gdzie rocznie płonie średnio 5 000 ha, redukcja spalonej powierzchni o 10% to 500 ha, czyli dziesiątki tysięcy ton niewyemitowanego CO2, plus uniknięte straty w drewnie i niższe koszty akcji gaśniczych.
- **Bilans:** emisja własna projektu to ułamek promila emisji unikniętej. ROI zdecydowanie dodatnie, nawet przy ostrożnych założeniach.

Prezentacja dla stakeholderów (6 slajdów)

- 1. Problem i jego skala w liczbach.
- 2. Jakie dane mamy i skąd (podkreślić: darmowe).
- 3. Jak to działa – bez matematyki, jeden obrazek z mapą ryzyka.
- 4. Wyniki pilotażu na danych historycznych.
- 5. Koszt vs korzyść, w złotówkach i tonach CO2.
- 6. Plan wdrożenia, ryzyka i co jest potrzebne od odbiorcy.

Zadanie 20 – Future of Green AI

> **Uwaga:** zgodnie z prośbą o zwięzłość poniżej jest skrócona wersja eseju (ok. 700 słów zamiast wymaganych w zadaniu 1000–1500). Struktura i bibliografia odpowiadają pełnej wersji – każdą sekcję można rozwinąć do wymaganej objętości.

Jak będzie wyglądał Green AI w 2030 roku?

Punkt wyjścia. Przez ostatnią dekadę rozwój AI napędzała prosta zasada: większy model to lepszy model. Zapłaciliśmy za to rachunkiem energetycznym, który przestał być marginalny – centra danych odpowiadają już za kilka procent światowego zużycia energii elektrycznej, a prognozy mówią o dalszym szybkim wzroście napędzanym właśnie przez AI. Green AI to nurt, który pyta nie tylko "jak dokładny jest model", ale też "jakim kosztem".

Trend 1: efektywność zamiast skali. Najważniejsza zmiana do 2030 roku nie będzie technologiczna, tylko mentalna – efektywność stanie się parametrem jakości modelu, a nie dodatkiem. Widać to już dziś: małe, dobrze wytrenowane modele dorównują modelom kilkukrotnie większym sprzed dwóch lat. Techniki, które to umożliwiają – destylacja, kwantyzacja, przycinanie sieci, architektury mixture-of-experts aktywujące tylko potrzebny fragment modelu – przestaną być optymalizacją na końcu projektu, a staną się punktem wyjścia. Osobno rośnie znaczenie **inference**: model trenuje się raz, a odpowiada miliardy razy, więc to tam leży większość realnego zużycia energii.

Trend 2: przesunięcie obliczeń na brzeg sieci. Coraz więcej modeli będzie działać lokalnie – na telefonie, w samochodzie, na sterowniku przemysłowym. To oszczędza nie tylko energię transmisji, ale też chroni prywatność. Do 2030 roku uruchomienie przyzwoitego modelu językowego na laptopie będzie czymś całkowicie zwyczajnym.

Trend 3: nowy sprzęt – z umiarkowanym optymizmem. Układy neuromorficzne, naśladujące sposób działania neuronów, obiecują zużycie energii niższe o rzędy wielkości dla pewnych klas zadań i mają realną szansę wyjść z laboratoriów do zastosowań niszowych. Komputery kwantowe pozostaną natomiast w 2030 roku ciekawostką badawczą dla uczenia maszynowego – nie należy na nich opierać żadnych planów. Znacznie większy praktyczny wpływ będą miały zwykłe, kolejne generacje akceleratorów i lepsze chłodzenie centrów danych.

Trend 4: regulacje. To tu zmiana będzie najostrzejsza. Unijny AI Act już wprowadza obowiązki dokumentacyjne, a kierunek jest jasny: raportowanie śladu węglowego modeli stanie się obowiązkowe, podobnie jak dziś etykiety energetyczne sprzętu AGD. Do 2030 roku należy oczekiwać standardowej "karty energetycznej" modelu – ile kosztowało trenowanie, ile kosztuje jedna odpowiedź, w jakim regionie i z jakiego miksu energetycznego. Firmy, które nie mierzą tego dziś, będą miały problem.

Napięcie: innowacja kontra środowisko. To napięcie jest realne, ale często źle stawiane. AI zużywa energię, ale jednocześnie pomaga ją oszczędzać – w prognozowaniu produkcji z OZE, zarządzaniu sieciami energetycznymi, optymalizacji przemysłu i transportu. Właściwym pytaniem nie jest "czy AI zużywa dużo prądu", tylko "czy dany projekt oszczędza więcej, niż kosztuje". Ten bilans trzeba liczyć dla konkretnego zastosowania, bo czasem wychodzi świetnie, a czasem wcale.

Rola Data Scientistów. To my podejmujemy decyzje, które realnie przekładają się na zużycie energii – i robimy to codziennie, często bezrefleksyjnie. Wybór modelu, liczba eksperymentów, częstotliwość retreningu, region chmury, to czy wynik jest cache'owany. Żadna z tych decyzji nie wymaga zgody zarządu, a razem decydują o rachunku.

Rekomendacje dla obecnych Data Scientists

- 1. **Mierz zużycie energii** swoich eksperymentów (np. CodeCarbon). Bez pomiaru nie ma optymalizacji.
- 2. **Zawsze zaczynaj od prostego baseline'u.** Często okaże się wystarczający – a bez niego nie wiesz, co zyskujesz na droższym modelu.
- 3. **Nie trenuj od zera, gdy istnieje gotowy model.** Transfer learning to najskuteczniejsza praktyka Green AI.
- 4. **Optymalizuj inference, nie tylko trening** – tam zwykle leży większość kosztu.
- 5. **Planuj eksperymenty.** Setka przypadkowych uruchomień kosztuje więcej niż dziesięć przemyślanych.
- 6. **Wybieraj region chmury z czystą energią** – ta sama praca, kilkukrotnie mniejsza emisja, zerowy koszt wdrożenia.
- 7. **Raportuj koszt energetyczny w dokumentacji modelu.** Niedługo będzie to obowiązek; lepiej mieć nawyk wcześniej.

Bibliografia

- 1. Schwartz R., Dodge J., Smith N. A., Etzioni O. (2020), *Green AI*, Communications of the

ACM, 63(12).

- 2. Strubell E., Ganesh A., McCallum A. (2019), *Energy and Policy Considerations for Deep Learning in NLP*, Proceedings of ACL.
- 3. Patterson D. et al. (2021), *Carbon Emissions and Large Neural Network Training*, arXiv:2104.10350.
- 4. Luccioni A. S., Viguier S., Ligozat A.-L. (2023), *Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model*, Journal of Machine Learning Research.
- 5. International Energy Agency (2024), *Electricity 2024: Analysis and Forecast to 2026* – rozdział o zużyciu energii przez centra danych i AI.
- 6. Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 (*AI Act*).